

(주)에셈블_정수장 공정 맞춤형 챗봇 개발

1. 프로젝트 개요

본 프로젝트는 정수장 공정 운영자의 질의에 대해 **정확하고 빠르게** 맞춤형 답변을 제공하는 챗봇 시스템을 개발하는 것을 목표로 한다.

챗봇은 오픈소스 LLM과 SLM을 기반으로 구축하며, PDF 등 다양한 문서에서 추출한 도메인 데이터를 활용하여 현장 운영에 특화된 자연어 응답을 제공한다.

2. 개발 범위 (챗봇 파트)

본 개발자는 전체 시스템 중 **챗봇 엔진 및 데이터 처리 파트**를 전담하며, 다음 기능을 구현한다.

1. 질문 해석 모듈 (LLM 기반)

- 사용자의 자연어 질문을 해석하고 의도를 파악.
- 질의 내용에서 핵심 요구사항 추출 (예: "침전지 이상 소독 처리량" → **침전지**, **소독 처리량**).

2. 데이터 매칭 모듈

- 사전 구축된 **정수장 공정 데이터베이스**에서 관련 문서/절차/규정 검색.
- 해당 데이터베이스는 PDF, 매뉴얼, 보고서 등에서 추출된 문서를 분석하여 **단락별 주제·태그**가 부여된 형태로 저장.
- 빠른 검색을 위해 벡터 DB(Faiss, Milvus 등) 활용.

3. 응답 생성 모듈 (LLM 기반)

- 검색된 데이터와 사용자 질문을 기반으로 자연어 응답 생성.
- 전문 용어 유지 + 사용자가 이해하기 쉬운 설명 제공.
- 불필요한 정보 제거 및 핵심 요약.

3. 시스템 구조

```
사용자 질문 → [질문 해석 LLM] → 요구사항 추출
      ↓
[데이터 검색 모듈] → 벡터DB에서 관련 데이터 로드
      ↓
[응답 생성 LLM] → 자연어 최종 답변 반환
```

4. 데이터 준비

- 데이터 출처**
 - 정수장 매뉴얼, 설계 보고서, 유지보수 지침, 법규 문서, 기술 보고서.
- 전처리 방식**
 - PDF/Word/Excel → 텍스트 변환 (pdfminer, unstructured, PyMuPDF)
 - 문단별 주제 분류, 키워드 태깅
 - 벡터화 (Sentence-BERT, KoSimCSE) → 벡터 DB 저장
- 검색 최적화**
 - 유사도 검색 + 키워드 필터링
 - 문서 메타데이터(공정명, 설비명, 규격 등) 기반 필터

5. 기술 스택 및 모델

오픈소스 LLM 후보 (정확도 & 한국어 지원)

모델명	특징	장점	단점
KoAlpaca / KoVicuna (LLaMA 기반)	한국어 특화 파인튜닝	한국어 질문 해석 및 응답 품질 우수	경량 버전 속도 제한
Polyglot-Ko (3.8B / 5.8B)	대규모 한국어 데이터 학습	속도·정확도 균형	5.8B는 GPU 메모리 요구 높음
OpenKo-LLM	한국어 QA에 특화	최신 LLaMA2 기반, 높은 정확도	상대적으로 배포 초기 단계
MPT-7B-Instruct (한국어 파인튜닝)	빠른 응답 속도	처리 속도 빠름	한국어 데이터셋 부족 시 품질 저하 가능

SLM 후보 (질문 의도 분석, 라우팅 등 경량 처리)

모델명	용도	장점
KoMiniLM	질문 의도 분석, 키워드 추출	가볍고 빠름
KoSimCSE	벡터 검색을 위한 문장 임베딩	한국어 유사도 검색 최적
DistilKoBERT	짧은 텍스트 분류	GPU 자원 절약

6. 기대 효과

- 현장 운영자가 **매뉴얼 검색 없이** 필요한 정보를 즉시 획득.
- 긴급 상황 시 빠른 대응 가능 (예: 수질 이상 발생 시 대처 방법).
- 신규 직원 교육 자료로 활용 가능.